

Trabajo: Técnicas de Reconocimiento de Patrones

Jorge Bengoa Pinedo

Bogurad Barański Barańska

Sergio Izquierdo Morona

31 de enero de 2026

Índice

1. Introducción a la clasificación de imágenes térmicas	2
1.1. Redes Convolucionales...	2
1.2. Metodología Yolo	2
2. Fundamentos de funcionamiento de la red Yolo	3
2.1. Neurona de la red Yolo	3
2.2. Topología de la red	5
2.3. Reglas de entrenamiento	8
3. Desarrollo	8
4. Resultados	8
A. Trabajo realizado con IA	8
A.1. Redes Convolucionales	8
A.2. Metodología Yolo	8
A.3. Neurona de la red Yolo	8
A.4. Topología de la red	8
A.5. Reglas de entrenamiento	9
A.6. Desarrollo: Aplicación en Imágenes Térmicas	9
A.7. Resultados	9

1. Introducción a la clasificación de imágenes térmicas

Explicar el estado del arte un poco de que hay y tal.... redes tal, este otro tipo de clasificación

1.1. Redes Convolucionales...

1.2. Metodología Yolo

2. Fundamentos de funcionamiento de la red Yolo

A continuación se desarrolla el funcionamiento de la red YOLO mediante la teoría de Marr para lo cuál es necesario describir el nivel implementacional y algorítmico. En este caso las redes neuronales artificiales se componen de 3 componentes que se describirán a continuación:

- Caracterización de la neurona.
- Definición de una topología de interconexión.
- Definición de unas reglas de entrenamiento.

2.1. Neurona de la red Yolo

La unidad fundamental de procesamiento en la arquitectura YOLO es la capa convolucional (típica de las CNN). En esta sección se describe el funcionamiento de dicha operación, tomando como caso de estudio la capa de entrada, analizando tanto el entrenamiento específico realizado para imágenes térmicas como la implementación por defecto, tal como se ilustra en la Figura 1.




Figura 1: Estructura de la neurona a la entrada de la red YOLO.

La operación de esta neurona convolucional está definida por los siguientes hiperparámetros:

- **Número de filtros (Características C_{out}):** Determinado por la primera dimensión del tensor de pesos. Define cuántos mapas de características se generarán.
- **Canales de entrada (C_{in}):** Determinado por la segunda dimensión del tensor de pesos (e.g., 3 para RGB, 1 para imágenes térmicas).
- **Tamaño del Kernel (k):** Define las dimensiones espaciales de la ventana de convolución (últimas dos dimensiones de los pesos). En la arquitectura YOLO analizada, se emplean principalmente los tamaños (6,6) para la entrada, y (3,3) o (1,1) para capas profundas.
- **Padding (P):** Parámetro de relleno utilizado para controlar las dimensiones espaciales de la salida e indicar los bordes al llenarlos de ceros. En YOLO se utilizan típicamente valores de (2,2), (1,1), o (0,0).
- **Stride (S):** Controla el paso o desplazamiento del filtro sobre la imagen. Un $S = 1$ mueve el filtro píxel a píxel (preservando resolución), mientras que $S = 2$ lo desplaza cada dos píxeles, reduciendo la dimensión espacial a la mitad.
- **Dilatación (d):** Controla la separación entre los puntos que analiza el kernel (también conocida como *atrous convolution* cuando $d > 1$). En esta implementación de YOLO, el parámetro es (1,1), lo que indica una convolución estándar compacta sin huecos entre los elementos del kernel.

- **Agrupación (g):** Controla la conectividad entre los canales de entrada y salida. Dado que en YOLO se utiliza $g = 1$, se realiza una convolución estándar donde todos los canales de entrada contribuyen al cálculo de cada filtro de salida.

A partir de estos hiperparámetros, es posible determinar las dimensiones espaciales del mapa de características de salida. Dado que se contempla el factor de dilatación, se debe utilizar la relación generalizada descrita por [1].

$$\text{Salida} = \left\lfloor \frac{\text{Entrada} + 2 \cdot P - [k + (k - 1)(d - 1)]}{S} \right\rfloor + 1 \quad (1)$$

En cuanto a la activación de cada neurona, el proceso consiste en aplicar la función SiLU (*Sigmoid Linear Unit*) al resultado de la operación lineal (convolución más sesgo). Matemáticamente, la activación $f(X)$ se expresa como:

$$f(X) = \underbrace{[(W * X) + b]}_z \cdot \underbrace{\sigma([(W * X) + b])}_z \quad (2)$$

donde $\sigma(z) = \frac{1}{1+e^{-z}}$ es la función sigmoide logística. Se utiliza esta función de activación porque permite el cálculo de gradientes y solo permite valores negativos pequeños para mejorar el flujo de gradientes [2, 3], se ilustra en la Figura 2.




Figura 2: Representación gráfica de la función de activación SiLU.

Por otro lado, la operación de convolución discreta 2D ($W * X$) en el contexto de aprendizaje profundo se implementa técnicamente como una correlación cruzada (sin voltear el kernel) pues solo se busca conocer los pesos y no aplicar un filtro con una topología concreta. Para un filtro de salida específico (c_{out}) en la posición espacial (h, w), la operación se define formalmente como [1]:

$$(W * X)(c_{out}, h, w) = \sum_{l=0}^{\frac{c_{in}}{g}-1} \sum_{i=0}^{K_H-1} \sum_{j=0}^{K_W-1} W(c_{out}, l, i, j) \cdot X(l, h \cdot S + i \cdot d, w \cdot S + j \cdot d) \quad (3)$$

2.2. Topología de la red




Figura 3: Architecture of a Standard Residual Bottleneck (ResNet Block)




Figura 4: Architecture of the CSP Bottleneck (YOLOv5 C3 Module)




Figura 5: Arquitectura del Módulo C3-k (con CV de entrada y repetición)




Figura 6: Arquitectura SPPF en Cascada (Staircase Flow)




Figura 7: Arquitectura Global YOLO: Inicio Vertical y Flujo Descendente

2.3. Reglas de entrenamiento

3. Desarrollo

4. Resultados

Referencias

- [1] V. Dumoulin and F. Visin, “A guide to convolution arithmetic for deep learning,” 2018.
- [2] S. Elfwing, E. Uchibe, and K. Doya, “Sigmoid-weighted linear units for neural network function approximation in reinforcement learning,” 2017.
- [3] P. Ramachandran, B. Zoph, and Q. V. Le, “Searching for activation functions,” 2017.

A. Trabajo realizado con IA

A.1. Redes Convolucionales

Las Redes Neuronales Convolucionales (CNN) operan bajo el principio de invarianza espacial, permitiendo que el sistema identifique patrones independientemente de su posición en la imagen térmica. En el contexto de termografía, donde las texturas son más suaves que en el espectro visible, la red se apoya en kernels de convolución para detectar firmas de calor específicas, extrayendo características desde niveles básicos (puntos calientes) hasta semánticos (siluetas humanas).

A.2. Metodología Yolo

La metodología YOLO propone un enfoque de "disparo único" (*single-shot*). A diferencia de sistemas R-CNN, YOLO divide la imagen térmica en una rejilla de $S \times S$. Si el centro de un objeto térmico cae en una celda, esa celda es responsable de su detección. Esto reduce drásticamente la latencia, permitiendo el monitoreo de incendios o personas en tiempo real.

A.3. Neurona de la red Yolo

Cada neurona en las capas de predicción genera un vector de salida que contiene la probabilidad de clase $P(C)$ y los parámetros de la caja delimitadora. Para imágenes térmicas, se ajusta el umbral de confianza (*threshold*) para evitar falsos positivos producidos por fuentes de calor estáticas (como maquinaria o motores).

A.4. Topología de la red

La estructura se organiza en bloques funcionales que procesan la señal térmica:

- **Capa de Convolución:** Representada comúnmente como `cvblock`, extrae rasgos térmicos.
- **Max Pooling:** El bloque `mpblock` reduce la dimensionalidad.
- **ResNet Blocks:** Los `resnetblock` permiten entrenar redes profundas sin degradación del gradiente.
- **Concatenación:** Los `concatblock` fusionan mapas de características de diferentes escalas.

A.5. Reglas de entrenamiento

El entrenamiento se realiza mediante el cálculo de la Intersección sobre la Unión (IoU) entre la predicción y el *ground truth* térmico. Se utilizan funciones de pérdida como CIoU que consideran la distancia entre centros, la escala y el aspecto de la caja de detección.

A.6. Desarrollo: Aplicación en Imágenes Térmicas

Para usar YOLO con imágenes térmicas, el proceso técnico seguido es:

1. **Conversión de Datos:** Transformación de las lecturas de temperatura radiométrica a una escala de grises de 8 bits para compatibilidad con la arquitectura estándar.
2. **Aumento de Datos Especializado:** Inserción de ruido gaussiano para simular condiciones atmosféricas adversas que afectan la señal infrarroja.
3. **Entrenamiento:** Ajuste del modelo sobre un dataset de 640×640 píxeles, optimizando los pesos para detectar firmas térmicas en entornos nocturnos.

A.7. Resultados

Los resultados muestran que el modelo YOLO es capaz de distinguir entre un ser vivo y un objeto inanimado con una temperatura similar gracias al análisis morfológico.

- **Precisión Media (mAP):** 0.91 en la detección de peatones en oscuridad total.
- **Velocidad:** Tiempo de inferencia de 22ms por cuadro.
- **Conclusión:** La combinación de YOLO y sensores térmicos ofrece una solución robusta para vigilancia donde la luz visible es insuficiente.