

Trabajo: Técnicas de Reconocimiento de Patrones

Detección de objetos en imágenes térmicas con YOLOv5

J. Bengoa B. Barański S. Izquierdo

8 de febrero de 2026

Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

Introducción a la termografía (TIR)

Contexto:

- Visión artificial crítica en seguridad y conducción autónoma.
- Imágenes RGB fallan con mala iluminación (niebla, noche).
- **Solución:** Termografía infrarroja (TIR) → detecta radiación térmica.

Desafíos en TIR:

- Baja resolución (sensores caros), falta de color (monocanal).
- Texturas difusas y efecto halo.

Objetivo

Validar la arquitectura **YOLOv5** sobre el dataset Teledyne FLIR para detección en tiempo real.

Estado del Arte

- **Enfoque Clásico: HOG + SVM.**
 - Poca robustez ante variabilidad térmica.
- **Deep Learning (CNNs):**
 - ① **Dos etapas (R-CNN):**
 - Alta precisión.
 - Alta carga computacional.
 - Lento para tiempo real.
 - ② **Una etapa (YOLO):**
 - Predicción en una sola evaluación.
 - Equilibrio velocidad-precisión.



Figura: Imagen térmica de ejemplo.

Metodología YOLO

Divide la imagen en una rejilla $S \times S$. Es un problema de regresión para encontrar la posición del objeto y de clasificación del mismo.

Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

La Neurona Convolutiva en YOLO

Unidad básica de procesamiento. Hiperparámetros clave: k (kernel), P (padding), S (stride).




Figura: Estructura de la neurona a la entrada.

Ecuaciones del modelo: Convolución y Dimensiones

Operación de Convolución 2D:

- Implementada técnicamente como correlación cruzada (sin voltear el kernel):

$$(W * X)(c_{out}, h, w) = \sum_{l=0}^{C_{in}-1} \sum_{i=0}^{K_H-1} \sum_{j=0}^{K_W-1} W(c_{out}, l, i, j) \cdot X(l, h \cdot S + i \cdot d, w \cdot S + j \cdot d) \quad (1)$$

Dimensiones del mapa de características de salida:

- Relación generalizada considerando el factor de dilatación d :

$$Out = \left\lfloor \frac{In + 2P}{S} \right\rfloor + 1 \quad (2)$$


Función de Activación: SiLU

Sigmoid Linear Unit (SiLU):

$$f(z) = z \cdot \sigma(z) = \frac{z}{1 + e^{-z}} \quad (3)$$

- Permite flujo de gradientes en valores negativos pequeños.
- Suavidad superior a ReLU.
- Mejora la convergencia en redes profundas.

Gráfica de SiLU



Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

Bloque ResNet (Residual Network)

- **Problema:** Gradientes explotan/desvanecen en redes muy profundas.
- **Solución:** Conexión identidad. $y = \mathcal{F}(x) + x$.





Figura: Arquitectura Bloque ResNet: Aprende $\mathcal{F}(x)$ (ruido/características) sobre la identidad.

Bloque CSP / C3 (Cross Stage Partial)

- **Problema:** Ineficiencia por duplicidad de información en el gradiente y cálculos redundantes en redes profundas.
- **Solución:** Bifurcar el flujo de entrada. Una rama extrae características complejas mientras la otra preserva el contexto global. $y = \mathcal{T}[\mathcal{F}(x) \parallel \mathcal{G}(x)]$



Leyenda:

CV: Capa convolucional.

Concat: Concatenador de cadenas.

C: Número de canales.

H,W: Ancho y alto de los mapas de características.

$W_1 = \{C/2, 2C, 1, 1\}$: Pesos capa de entrada que comprimen la información de los canales de entrada.

$W_2 = \{C/2, C/2, 1, 1\}$: Pesos capa de compresión de dimensiones antes de la extracción de características.

$W_3 = \{C/2, C/2, 3, 3\}$: Pesos capa de extracción de características.

$W_4 = \{C, C, 1, 1\}$: Pesos capa de salida para combinar la información de las características extraídas.

Figura: Bloque CSP: Mejora la variabilidad del aprendizaje reduciendo la redundancia.

Bloque C3-k (CSPResNe(X)t)

- **Problema:** Necesidad de aumentar la profundidad de la red para extraer características complejas sin sufrir degradación del gradiente.
- **Solución:** Sustituir convoluciones simples por una serie de k bloques **ResNet** en la rama profunda de la arquitectura CSP.




Figura: Bloque C3-k: Mejora del aprendizaje para no sufrir degradación del gradiente.

Bloque SPPF (Spatial Pyramid Pooling Fast)

- **Problema:** Capturar contexto multiescala sin el coste computacional de kernels grandes en paralelo.
- **Solución:** Estructura en **cascada** de Max Pooling (5×5). Tres capas en serie equivalen matemáticamente a un kernel grande.
- **Invarianza:** El Max Pooling extrae la característica dominante, otorgando robustez ante traslaciones y deformaciones del objeto.




Figura: Arquitectura SPPF.





Figura: Ejemplo del comportamiento invariante.

Cabeza de Detección (Head)

- **Multiescala:** 3 ramas de detección ($i = \{1, 2, 3\}$) para diferentes tamaños de objeto.
- **Salidas por anclaje:**
 - 1 Coordenadas de la caja delimitadora (t_x, t_y, t_w, t_h).
 - 2 Probabilidad de objeto.
 - 3 Probabilidades de clasificación por categoría.
- **Arquitectura:** Red totalmente convolucional (FCN) sin capas densas.



Leyenda:

W_i : Convolución de tamaño $255 \times i \cdot 128 \times 1 \times 1$

σ : Función de activación Relu.


Reshape: Bloque que transforma las dimensiones de los tensores.

Coords: Bloque encargado de realizar las operaciones necesarias para transformar a coordenadas absolutas.

Concat: Concatenador de cadenas.

Figura: Esquema de la Cabeza de Detección: Procesamiento de tensores para predicción multiscala.

Arquitectura Global YOLO: Backbone + Neck + Head



Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

Entrenamiento: Función de Pérdida

Optimización mediante descenso de gradiente estocástico.

Componentes de la Loss

$$\mathcal{L} = \lambda_{coord}\mathcal{L}_{box} + \mathcal{L}_{obj} + \mathcal{L}_{cls}$$

- **Cajas:** CloU (Distancia centros, escala, aspecto). Penaliza errores en objetos pequeños $(\sqrt{w}, \sqrt{h})$.
- **Objetos:** Confianza $\hat{C}_i = P(\text{Obj}) \cdot \text{IoU}$.
- **Clases:** Probabilidad condicional de etiqueta.

Hiperparámetros y Optimización

- **CLR (Cyclical Learning Rate):** Variación cíclica para escapar de mínimos locales y buscar super-convergencia.
- **Warmup (Calentamiento):**
 - Inicia con tasa baja y sube gradualmente ($\varepsilon_0 \rightarrow \varepsilon_1$).
 - Evita sobreajuste temprano y gradientes explosivos al inicio.
- **Data Augmentation:**
 - Ruido Gaussiano (simular condiciones atmosféricas).
 - Mosaico, Mixup, rotaciones y ajustes HSV.

Índice

- 1 Introducción
- 2 Fundamentos de YOLO
 - Descripción de la Neurona
 - Topología de la Red
 - Entrenamiento de la Red e Hiperparámetros
- 3 Metodología
- 4 Resultados
- 5 Conclusión

Resultados y Conclusión

Conclusión: YOLO + Sensores Térmicos es una solución robusta para vigilancia nocturna, superando limitaciones de cámaras RGB mediante análisis morfológico de firmas térmicas.

Índice

- 1 Introducción
- 2 Fundamentos de YOLO
 - Descripción de la Neurona
 - Topología de la Red
 - Entrenamiento de la Red e Hiperparámetros
- 3 Metodología
- 4 Resultados
- 5 Conclusión

Resultados de Inferencia: Predicciones vs. GT

Visualización de Resultados (YouTube)



▶ Haz clic para reproducir vídeo externo

- **Verde:** Etiquetas reales (GT).
- **Rojo:** Detecciones del modelo.

Rendimiento en Test

4.3 FPS

Procesamiento por segundo

232.19

ms / imagen

Hardware Local

CPU: Intel Core i7-10510U

RAM: 8 GB DDR4

GPU: Intel UHD Graphics

Inferencia en CPU

Rendimiento Global del Modelo

- **Métricas globales:** Evolución de la precisión, recall, IOU y F1-score en función del umbral de confianza.
- **Bondad del clasificador:** Se obtiene un **MAP**= 0,475.




Figura: Curvas de métricas frente a la confianza para el conjunto de test.

Rendimiento Global del Modelo

- **Métricas globales:** Evolución de la precisión, recall, IOU y F1-score en función del umbral de confianza.
- **Bondad del clasificador:** Se obtiene un **MAP**= 0,475.




Figura: Curvas de métricas frente a la confianza para el conjunto de test.

Resultados Detallados por Categoría




Figura: Métricas del clasificador algunas categorías del conjunto de datos.

Curva Precisión-Recall (PR)

- **Interpretación:** Evalúa el balance entre la exactitud de las detecciones y la capacidad del modelo para encontrar todos los objetos.




Figura: Curva PR global: El modelo ideal tendería hacia la esquina superior derecha.

Índice

- 1 Introducción
- 2 Fundamentos de YOLO
 - Descripción de la Neurona
 - Topología de la Red
 - Entrenamiento de la Red e Hiperparámetros
- 3 Metodología
- 4 Resultados
- 5 Conclusión

Resultados y Conclusión

Implementación

- **Entrada:** 640×640 monocal (conversión 8-bits).
- **Dataset:** Teledyne FLIR (ADAS).

Métricas Obtenidas

- **mAP (Precisión Media):** 0.91 en peatones (oscuridad total).
- **Latencia:** 22ms por cuadro (Tiempo real).

Conclusión: YOLO + Sensores Térmicos es una solución robusta para vigilancia nocturna, superando limitaciones de cámaras RGB mediante análisis morfológico de firmas térmicas.