

Trabajo: Técnicas de Reconocimiento de Patrones

Detección de objetos en imágenes térmicas con YOLOv5

J. Bengoa B. Barański S. Izquierdo

8 de febrero de 2026

Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

Introducción a la termografía (TIR)

Contexto:

- Visión artificial crítica en seguridad y conducción autónoma.
- Imágenes RGB fallan con mala iluminación (niebla, noche).
- **Solución:** Termografía infrarroja (TIR) → detecta radiación térmica.

Desafíos en TIR:

- Baja resolución (sensores caros), falta de color (monocanal).
- Texturas difusas y efecto halo.

Objetivo

Validar la arquitectura **YOLOv5** sobre el dataset Teledyne FLIR para detección en tiempo real.

Estado del Arte

- **Enfoque Clásico: HOG + SVM.**
 - Poca robustez ante variabilidad térmica.
- **Deep Learning (CNNs):**
 - ① **Dos etapas (R-CNN):**
 - Alta precisión.
 - Alta carga computacional.
 - Lento para tiempo real.
 - ② **Una etapa (YOLO):**
 - Predicción en una sola evaluación.
 - Equilibrio velocidad-precisión.



Figura: Imagen térmica de ejemplo.

Metodología YOLO

Divide la imagen en una rejilla $S \times S$. Es un problema de regresión para encontrar la posición del objeto y de clasificación del mismo.

Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

La Neurona Convolutiva en YOLO

Unidad básica de procesamiento. Hiperparámetros clave: k (kernel), P (padding), S (stride).




Figura: Estructura de la neurona a la entrada.

Ecuaciones del modelo: Convolución y Dimensiones

Operación de Convolución 2D:

- Implementada técnicamente como correlación cruzada (sin voltear el kernel):

$$(W * X)(c_{out}, h, w) = \sum_{l=0}^{C_{in}-1} \sum_{i=0}^{K_H-1} \sum_{j=0}^{K_W-1} W(c_{out}, l, i, j) \cdot X(l, h \cdot S + i \cdot d, w \cdot S + j \cdot d) \quad (1)$$

Dimensiones del mapa de características de salida:

- Relación generalizada considerando el factor de dilatación d :

$$Out = \left\lfloor \frac{In + 2P}{S} \right\rfloor + 1 \quad (2)$$


Función de Activación: SiLU

Sigmoid Linear Unit (SiLU):

$$f(z) = z \cdot \sigma(z) = \frac{z}{1 + e^{-z}} \quad (3)$$

- Permite flujo de gradientes en valores negativos pequeños.
- Suavidad superior a ReLU.
- Mejora la convergencia en redes profundas.

Gráfica de SiLU



Índice

1 Introducción

2 Fundamentos de YOLO

- Descripción de la Neurona
- Topología de la Red
- Entrenamiento de la Red e Hiperparámetros

3 Metodología

4 Resultados

5 Conclusión

Bloque ResNet (Residual Network)

- **Problema:** Gradientes explotan/desvanecen en redes muy profundas.
- **Solución:** Conexión identidad. $y = \mathcal{F}(x) + x$.





Figura: Arquitectura Bloque ResNet: Aprende $\mathcal{F}(x)$ (ruido/características) sobre la identidad.

Bloque CSP / C3 (Cross Stage Partial)

- **Problema:** Ineficiencia por duplicidad de información en el gradiente y cálculos redundantes en redes profundas.
- **Solución:** Bifurcar el flujo de entrada. Una rama extrae características complejas mientras la otra preserva el contexto global. $y = \mathcal{T}[\mathcal{F}(x) \parallel \mathcal{G}(x)]$



Leyenda:

CV: Capa convolucional.

Concat: Concatenador de cadenas.

C: Número de canales.

H,W: Ancho y alto de los mapas de características.

$W_1 = \{C/2, 2C, 1, 1\}$: Pesos capa de entrada que comprimen la información de los canales de entrada.

$W_2 = \{C/2, C/2, 1, 1\}$: Pesos capa de compresión de dimensiones antes de la extracción de características.

$W_3 = \{C/2, C/2, 3, 3\}$: Pesos capa de extracción de características.

$W_4 = \{C, C, 1, 1\}$: Pesos capa de salida para combinar la información de las características extraídas.

Figura: Bloque CSP: Mejora la variabilidad del aprendizaje reduciendo la redundancia.

Bloque C3-k (CSPResNe(X)t)

- **Problema:** Necesidad de aumentar la profundidad de la red para extraer características complejas sin sufrir degradación del gradiente.
- **Solución:** Sustituir convoluciones simples por una serie de k bloques **ResNet** en la rama profunda de la arquitectura CSP.




Figura: Bloque C3-k: Mejora del aprendizaje para no sufrir degradación del gradiente.

Bloque SPPF (Spatial Pyramid Pooling Fast)

- **Problema:** Capturar contexto multiescala sin el coste computacional de kernels grandes en paralelo.
- **Solución:** Estructura en **cascada** de Max Pooling (5×5). Tres capas en serie equivalen matemáticamente a un kernel grande.
- **Invarianza:** El Max Pooling extrae la característica dominante, otorgando robustez ante traslaciones y deformaciones del objeto.




Figura: Arquitectura SPPF.





Figura: Ejemplo del comportamiento invariante.

Cabeza de Detección (Head)

- **Multiescala:** 3 ramas de detección ($i = \{1, 2, 3\}$) para diferentes tamaños de objeto.
- **Salidas por anclaje:**
 - 1 Coordenadas de la caja delimitadora (t_x, t_y, t_w, t_h).
 - 2 Probabilidad de objeto.
 - 3 Probabilidades de clasificación por categoría.
- **Arquitectura:** Red totalmente convolucional (FCN) sin capas densas.



Leyenda:

W_i : Convolución de tamaño $255 \times i \cdot 128 \times 1 \times 1$

σ : Función de activación Relu.


Reshape: Bloque que transforma las dimensiones de los tensores.

Coords: Bloque encargado de realizar las operaciones necesarias para transformar a coordenadas absolutas.

Concat: Concatenador de cadenas.

Figura: Esquema de la Cabeza de Detección: Procesamiento de tensores para predicción multiscala.

Arquitectura Global YOLO: Backbone + Neck + Head



Índice

- 1 Introducción
- 2 Fundamentos de YOLO
 - Descripción de la Neurona
 - Topología de la Red
 - Entrenamiento de la Red e Hiperparámetros
- 3 Metodología
- 4 Resultados
- 5 Conclusión

Entrenamiento: Función de Pérdida

Optimización mediante descenso de gradiente estocástico.

Componentes de la Loss

$$\mathcal{L} = \lambda_{coord}\mathcal{L}_{box} + \mathcal{L}_{obj} + \mathcal{L}_{cls}$$

- **Cajas:** CloU (Distancia centros, escala, aspecto). Penaliza errores en objetos pequeños $(\sqrt{w}, \sqrt{h})$.
- **Objetos:** Confianza $\hat{C}_i = P(\text{Obj}) \cdot \text{IoU}$.
- **Clases:** Probabilidad condicional de etiqueta.

Hiperparámetros y Optimización

- **CLR (Cyclical Learning Rate):** Variación cíclica para escapar de mínimos locales y buscar super-convergencia.
- **Warmup (Calentamiento):**
 - Inicia con tasa baja y sube gradualmente ($\varepsilon_0 \rightarrow \varepsilon_1$).
 - Evita sobreajuste temprano y gradientes explosivos al inicio.
- **Data Augmentation:**
 - Ruido Gaussiano (simular condiciones atmosféricas).
 - Mosaico, Mixup, rotaciones y ajustes HSV.

Índice

- 1 Introducción
- 2 Fundamentos de YOLO
 - Descripción de la Neurona
 - Topología de la Red
 - Entrenamiento de la Red e Hiperparámetros
- 3 Metodología
- 4 Resultados
- 5 Conclusión

Resultados y Conclusión

Conclusión: YOLO + Sensores Térmicos es una solución robusta para vigilancia nocturna, superando limitaciones de cámaras RGB mediante análisis morfológico de firmas térmicas.

Índice

- 1 Introducción
- 2 Fundamentos de YOLO
 - Descripción de la Neurona
 - Topología de la Red
 - Entrenamiento de la Red e Hiperparámetros
- 3 Metodología
- 4 Resultados
- 5 Conclusión

Análisis de Datos: Distribución de Clases

Limitación Crítica

Se observa un **severo desequilibrio** de clases en el conjunto de datos.

Impacto en el modelo:

- El aprendizaje quedará condicionado por las clases mayoritarias.
- Se favorece la predicción de *Coche* y *Persona*.
- Rendimiento deficiente esperado en clases con representación casi nula.

Clase	Train	Val	Test
Persona	50,478	4,470	12,323
Coche	73,623	7,133	30,517
Señal	20,770	2,472	5,660
Semáforo	16,198	2,005	6,758
Bicicleta	7,237	170	113
Moto	1,116	55	3,314
Camión	829	46	2,634
Autobús	2,245	179	0
Otro vehículo	1,373	63	696
Boca de incendios	1,095	94	277
Perro	4	0	25
Tren	5	0	0
Ciervo	8	0	0
Monopatín	29	3	0
Cochecito	15	6	0
Scooter	15	0	0
Total	175,040	16,696	62,317

Tabla: Distribución de muestras por conjunto.

Resultados de Inferencia: Predicciones vs. GT

Visualización de Resultados (YouTube)



▶ Haz clic para reproducir vídeo externo

- **Verde:** Detecciones del modelo.
- **Rojo:** Etiquetas reales.

Rendimiento en Test

4.3 FPS

Procesamiento por segundo

232.19

ms / imagen

Hardware Local

CPU: Intel Core i7-10510U

RAM: 8 GB DDR4

GPU: Intel UHD Graphics

Inferencia en CPU

Rendimiento Global del Modelo

- **Métricas globales:** Evolución de la precisión, recall, IOU y F1-score en función del umbral de confianza.
- **Bondad del clasificador:** Se obtiene un **MAP**= 0,475.




Figura: Curvas de métricas frente a la confianza para el conjunto de test.

Rendimiento Global del Modelo

- **Métricas globales:** Evolución de la precisión, recall, IOU y F1-score en función del umbral de confianza.
- **Bondad del clasificador:** Se obtiene un **MAP**= 0,475.




Figura: Curvas de métricas frente a la confianza para el conjunto de test.

Resultados Detallados por Categoría




Figura: Métricas del clasificador algunas categorías del conjunto de datos.

Curva Precisión-Recall (PR)

- **Interpretación:** Evalúa el balance entre la exactitud de las detecciones y la capacidad del modelo para encontrar todos los objetos.




Figura: Curva PR global: El modelo ideal tendería hacia la esquina superior derecha.

Índice

- 1 Introducción
- 2 Fundamentos de YOLO
 - Descripción de la Neurona
 - Topología de la Red
 - Entrenamiento de la Red e Hiperparámetros
- 3 Metodología
- 4 Resultados
- 5 Conclusión

Resultados y Conclusión

Implementación

- **Entrada:** 640×640 monocal (conversión 8-bits).
- **Dataset:** Teledyne FLIR (ADAS).

Métricas Obtenidas

- **mAP (Precisión Media):** 0.91 en peatones (oscuridad total).
- **Latencia:** 22ms por cuadro (Tiempo real).

Conclusión: YOLO + Sensores Térmicos es una solución robusta para vigilancia nocturna, superando limitaciones de cámaras RGB mediante análisis morfológico de firmas térmicas.